

Beautifulsoup & Selenium 사용법 레포트

2603340032 남종희

- BeautifulSoup

1. 객체 생성

HTML 이나 XML 텍스트를 분석 가능한 '트리 구조'로 변환하는 단계입니다. 이때 어떤 파서(Parser)를 사용하느냐에 따라 성능과 결과가 달라질 수 있습니다.

- **html.parser:** 파이썬 표준 라이브러리로 별도 설치가 필요 없으나 속도가 보통입니다.
- **lxml:** 매우 빠른 속도와 유연한 해석 능력을 갖추어 실무에서 가장 많이 선호됩니다.
- **html5lib:** 웹 브라우저와 가장 유사한 방식으로 HTML 을 해석하지만 속도가 느립니다.

2. 데이터 탐색 및 검색

원하는 데이터가 담긴 특정 지점을 찾아가는 과정입니다. BeautifulSoup 은 크게 두 가지 검색 방식을 제공합니다.

메서드 기반 검색 (find / find_all)

태그의 이름과 속성(class, id 등)을 직접 지정하여 찾는 방식입니다.

- **단일 요소 탐색 (find):** 조건에 맞는 가장 첫 번째 태그 하나만 가져옵니다. (예: 페이지의 제목 하나만 찾을 때)
- **복수 요소 탐색 (find_all):** 조건에 맞는 모든 태그를 리스트 형태로 반환합니다. (예: 뉴스 목록의 모든 제목을 가져올 때)

선택자 기반 검색 (select / select_one)

CSS 선택자 문법을 사용하여 위치를 지정하는 방식입니다. HTML 구조가 복잡할 때 매우 강력합니다.

- **계층 구조 활용:** `div > ul > li` 와 같이 부모-자식 관계를 명시하여 정확한 위치를 타겟팅할 수 있습니다.
- **직관적 표현:** 클래스는 마침표(.), 아이디는 샵(#) 기호를 사용하여 직관적으로 요소를 지목합니다.

3. 데이터 추출

원하는 태그를 찾았다면, 그 안에 담긴 구체적인 값을 꺼내오는 단계입니다.

- **텍스트 추출 (`get_text()` / `.string`):** 태그 내부에 포함된 순수한 문자열 데이터만 가져옵니다. (예: 기사 제목 텍스트)
- **속성값 추출 (`get('속성명') / ['속성명']`):** 태그가 가지고 있는 부가 정보인 속성값을 가져옵니다.
 - `<a>` 태그의 `href` (링크 주소)
 - `<img>` 태그의 `src` (이미지 경로)

4. 트리 구조 이동

단순 검색 외에도, 현재 찾은 태그를 기준으로 주변 태그로 이동하며 데이터를 찾을 수 있습니다.

- **부모/자식 이동:** 특정 데이터의 상위 항목이나 하위 항목으로 이동
- **형제 이동:** 같은 층위에 있는 이전(`previous_sibling`) 혹은 다음(`next_sibling`) 데이터로 이동 (예: '이름' 태그 옆에 있는 '나이' 태그 데이터 찾기)

- Selenium

1. 브라우저 드라이버와 서비스 제어

셀레니움은 브라우저를 직접 실행하기 위해 '웹드라이버'라는 중간 매개체를 사용합니다.

- **작동 원리:** 파이썬 코드가 드라이버에 명령을 전달하면, 드라이버는 이를 브라우저 전용 프로토콜로 변환해 실행합니다.
- **옵션 설정 (Options):** 브라우저를 실행할 때 여러 환경을 설정할 수 있습니다.
 - **Headless 모드:** 실제 브라우저 창을 띄우지 않고 메모리 상에서만 실행하여 리소스를 절약합니다.
 - **User-Agent 설정:** 자동화 봇이 아닌 일반 사용자로 인식되도록 브라우저 정보를 위장합니다.

2. 정밀한 요소 타겟팅

웹 페이지의 구조가 복잡할수록 요소를 정확히 찾는 기술이 중요합니다.

- **XPath 활용:** HTML의 절대적/상대적 경로를 이용해 요소를 찾습니다. 텍스트 내용이나 복합적인 조건을 걸어 요소를 찾을 때 매우 강력합니다. (예: "텍스트가 '로그인'인 버튼을 찾아라")
- **CSS Selector:** 웹 디자인에 사용되는 문법을 그대로 사용하여 속도가 빠르고 가독성이 높습니다.
- **다중 요소 탐색:** `find_elements`를 사용하여 조건에 맞는 모든 항목(예: 상품 목록 전체)을 리스트로 수집합니다.

3. 동적 상호작용

사용자가 브라우저에서 수행하는 모든 물리적 동작을 시뮬레이션합니다.

- **텍스트 제어:** 검색창 등에 값을 입력하는 `send_keys()`와 기존 내용을 지우는 `clear()`를 사용합니다.
- **마우스 제어:** 단순 클릭(`click()`) 외에도 마우스 커서를 특정 위치로 옮기거나(Hover), 드래그 앤 드롭 동작을 수행할 수 있습니다.
- **스크립트 실행 (`execute_script`):** 자바스크립트 명령어를 브라우저에 직접 주입합니다. 특히 페이지를 끝까지 내리는 '무한 스크롤' 구현 시 필수적입니다.

4. 지능적 대기 시스템

동적 웹페이지 크롤링의 성패는 '로딩 속도'를 어떻게 제어하느냐에 달려 있습니다.

- **명시적 대기 (`Explicit Wait`):** 특정 요소가 화면에 나타나거나(Presence), 클릭 가능해질 때까지(Clickable)만 지능적으로 기다립니다. 프로그램의 안정성을 높이는 가장 중요한 기능입니다.
- **상태 확인:** 페이지가 완전히 로드되었는지, 특정 팝업이 사라졌는지 등의 상태를 체크하며 다음 단계로 넘어갑니다.

5. 윈도우 및 프레임 관리

복잡한 웹사이트의 구조를 넘나드는 기술입니다.

- **iFrame 전환 (switch_to.frame):** 네이버 블로그나 카페처럼 HTML 안에 또 다른 HTML 페이지가 삽입된 경우, 해당 영역으로 포커스를 이동시켜야 데이터를 읽을 수 있습니다.
- **탭/창 관리:** 링크를 클릭해 새 탭이 열렸을 때, 제어권을 새 창으로 넘겨주는 작업을 수행합니다.